C.E.S.A.R school

Aprendizado de Máquina

Árvores de Decisão

2026 | Fevereiro

Vimos que podemos aprender medindo distância

E se aprender fosse apenas fazer as perguntas certas?

Árvore de Decisão

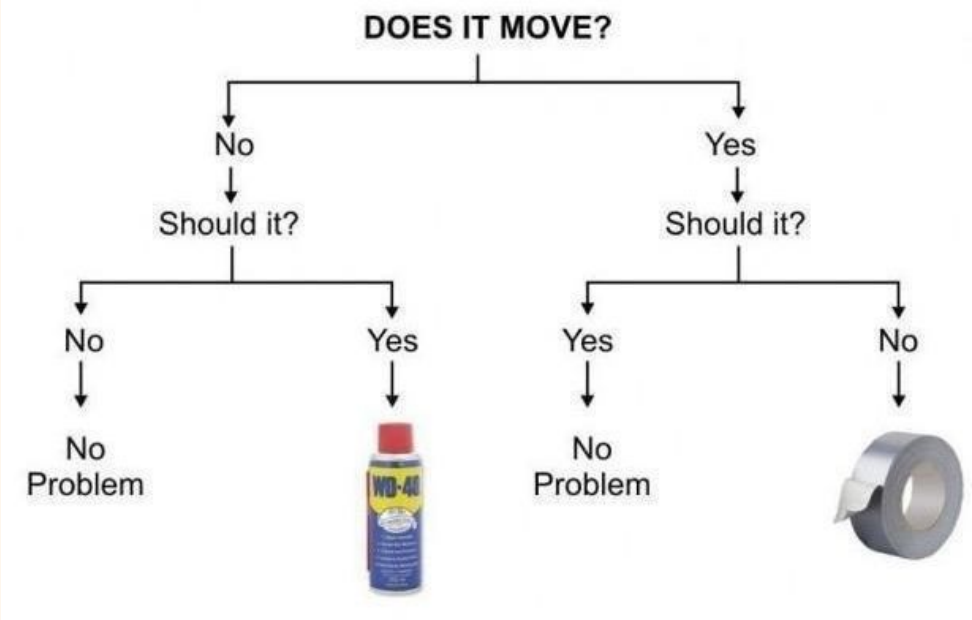

Árvore de Decisão

- Técnica de aprendizado supervisionado usada tanto para **classificação** quanto para **regressão**
- Estrutura em formato de árvore, onde cada **nó interno representa uma decisão** baseada em um **atributo** e cada **folha representa** uma **classe** ou resultado
- Não requer muita preparação de dados (ex.: normalização)
- Você provavelmente já usa e nem percebeu ainda

Árvore de Decisão

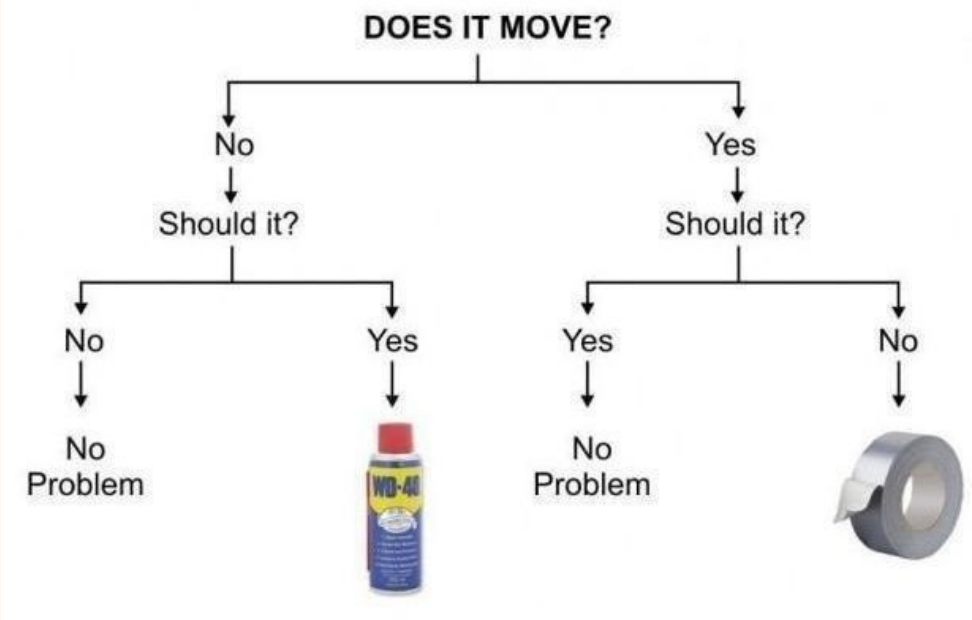

Vantagens

- Árvores de decisão transformam esse processo humano de perguntas em um **modelo** matemático
  - Fáceis de interpretar
  - **Explicáveis** para não técnicos
  - Funcionam para **classificação** e **regressão**
  - Base para modelos mais avançados (Random Forest, Boosting)

Relembrando...

- O **primeiro nó** de decisão é chamado de nó raiz **(Root Node)**
- Todos os **nós que se dividem em "nós filhos"**, são chamados de nó de decisão **(Decision Node)**
- Os **nós finais**, que não se dividem mais, são chamados de nó folha **(Leaf Node)**
- **Cada seta** representando uma divisão é chamada de galho/ramo **(Branch)**
- A **profundidade** indica **quantas decisões consecutivas** são necessárias para chegar a uma **predição final**.

Exemplo: Iris dataset

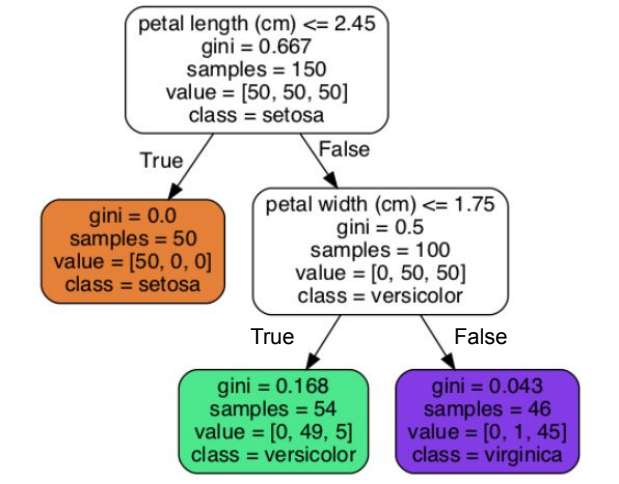

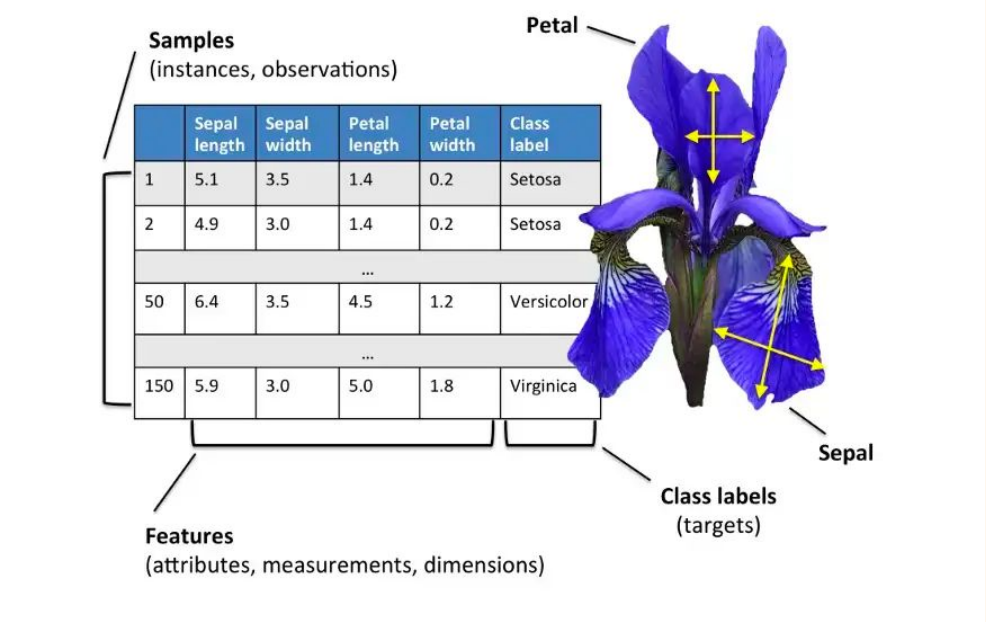

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

Exemplo: Iris dataset

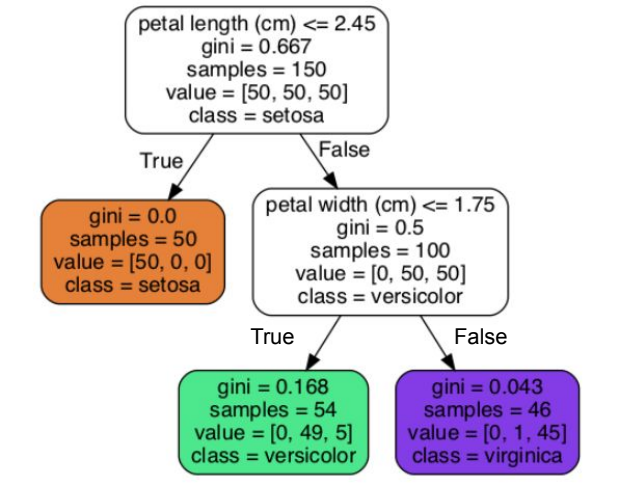

Profundidade: 2

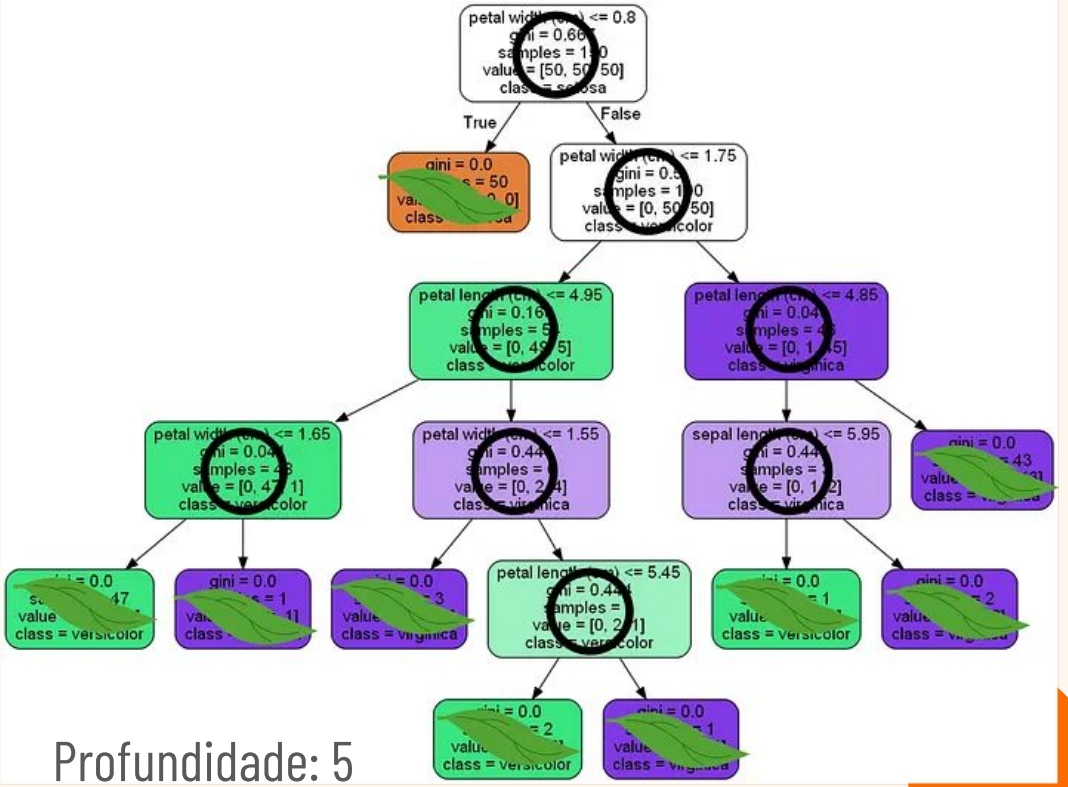

Profundidade: 5

Em vez de memorizar exemplos, podemos derivar uma estrutura que explique os dados

Problema: praticar ou não esporte?

- **Atributos**: tempo (ensolarado, nublado, chuvoso), umidade (alta, baixa), vento (fraco, forte)

Tempo	Umidade	Vento	Praticar Esporte
Ensolarado	Alta	Fraco	Não
Ensolarado	Alta	Forte	Não
Nublado	Alta	Fraco	Sim
Chuvoso	Baixa	Fraco	Sim
Chuvoso	Alta	Forte	Não

Problema: praticar ou não esporte?

- **Passo 1:** Qual atributo parece separar melhor 'Sim' e 'Não'?
- **Passo 2:** Qual categoria já ficou pura?
- **Passo 3:** Escolhemos o atributo que deixa os grupos mais organizados?
- **Passo 4**: Para cada folha
  - Se todos os exemplos são da mesma classe, associar essa classe à folha
  - Senão repetir os passos 1 a 4

Problema: praticar ou não esporte?

- **Passo 1:** Qual atributo parece separar melhor 'Sim' e 'Não'?
- **Passo 2:** Qual categoria já ficou pura?
- **Passo 3:** Escolhemos o atributo que deixa os grupos mais organizados?
- **Passo 4**: Para cada folha
  - Se todos os exemplos são da mesma classe, associar essa classe à folha
  - Senão repetir os passos 1 a 4

Tempo	Umidade	Vento	Praticar Esporte
Ensolarado	Alta	Fraco	Não
Ensolarado	Alta	Forte	Não
Nublado	Alta	Fraco	Sim
Chuvoso	Baixa	Fraco	Sim
Chuvoso	Alta	Forte	Não

Problema: praticar ou não esporte?

Tempo	Umidade	Vento	Praticar Esporte
Ensolarado	Alta	Fraco	Não
Ensolarado	Alta	Forte	Não
Nublado	Alta	Fraco	Sim
Chuvoso	Baixa	Fraco	Sim
Chuvoso	Alta	Forte	Não

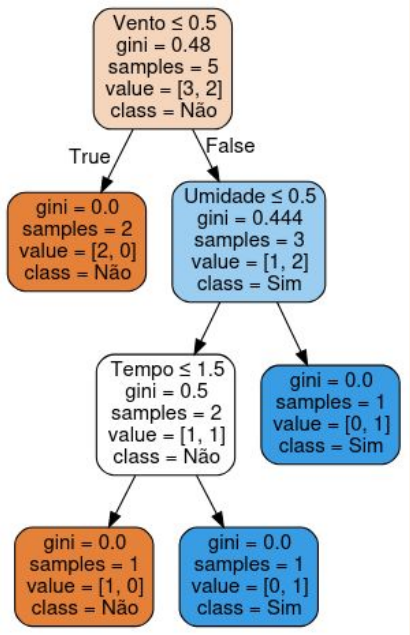

Isso significa que Tempo é o atributo mais importante?

Importância dos atributos

- A importância de um atributo está relacionada ao **quanto ele contribui** para organizar os dados ao longo da árvore
- Atributos usados **perto da raiz tendem a impactar mais exemplos**
- Atributos que **aparecem várias vezes influenciam várias decisões**
- Atributos que deixam grupos mais "**puros**" têm **maior relevância**

Exercício

Day	Outlook	Temp	Humidity	Wind	Tennis?
1	Sunny	Mild	High	Strong	No
2	Rain	Hot	Normal	Strong	No
3	Rain	Cool	High	Strong	No
4	Overcast	Hot	High	Strong	Yes
5	Overcast	Cool	Normal	Weak	Yes
6	Rain	Hot	High	Weak	Yes
7	Overcast	Mild	Normal	Weak	Yes
8	Overcast	Cool	High	Weak	Yes
9	Rain	Cool	High	Weak	Yes
10	Rain	Mild	Normal	Strong	No
11	Overcast	Mild	High	Weak	Yes
12	Sunny	Mild	Normal	Weak	Yes
13	Sunny	Cool	High	Strong	No
14	Sunny	Cool	High	Weak	No

- **Passo 1:** Qual atributo parece separar melhor 'Sim' e 'Não'?
- **Passo 2:** Qual categoria já ficou pura?
- **Passo 3:** Escolhemos o atributo que deixa os grupos mais organizados?
- **Passo 4**: Para cada folha
  - Se todos os exemplos são da mesma classe, associar essa classe à folha
  - Senão repetir os passos 1 a 4

Superfície de decisão

- O espaço é particionado em **regiões retangulares** (ou hiper-retangulares), e cada região corresponde a uma folha da árvore
- Cada novo nível da árvore adiciona um novo corte no espaço de atributos
- **Árvores** mais **profundas** produzem **superfícies** mais fragmentadas e **complexas**

Exemplo: Iris dataset

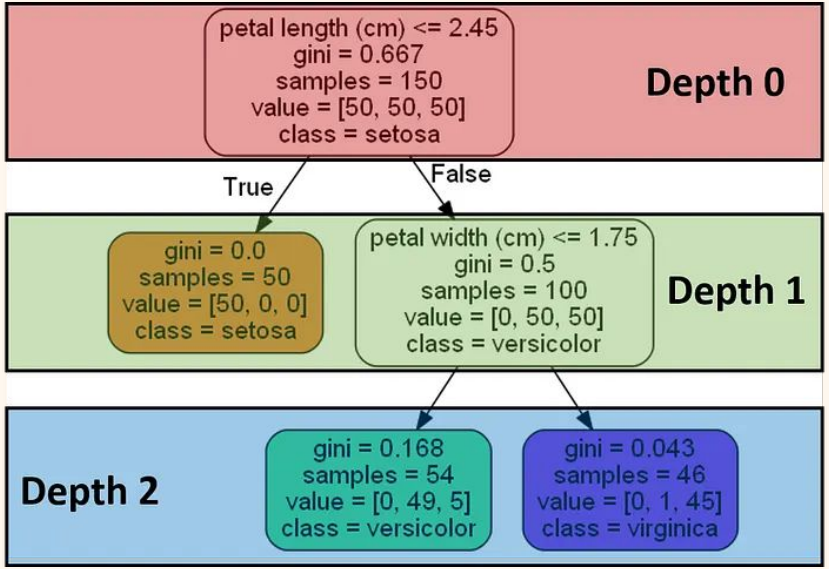

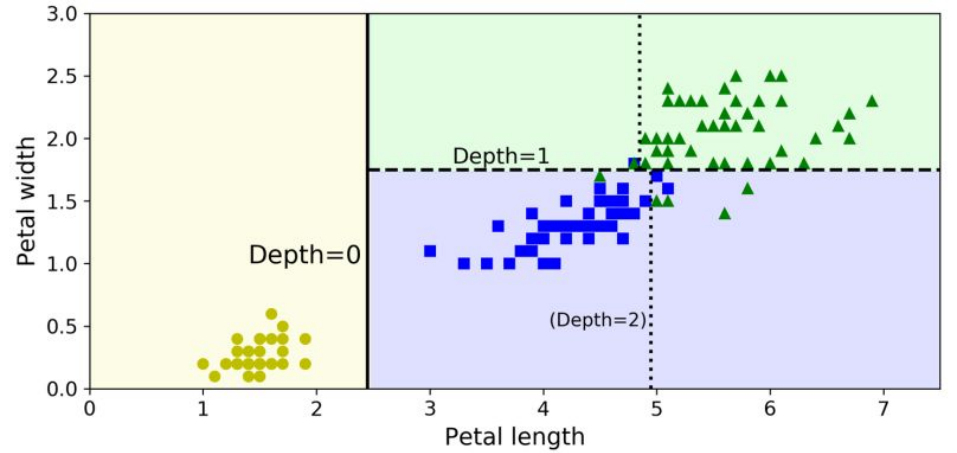

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - Capítulo 6

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb