C.E.S.A.R school

Aprendizado de Máquina

Árvores de Decisão

2026 | Fevereiro

Nem todo caminho que leva ao acerto é o caminho correto.

Construindo Árvores de Decisão

Palavras-chave	Links Externos	Dominio	Spam
Contem	Sim	Novo	1
Nao contem	Nao	Novo	1
Nao contem	Sim	Antigo	0
Contem	Nao	Novo	0
Contem	Sim	Novo	1
Contem	Sim	Antigo	1
Nao contem	Nao	Antigo	0
Contem	Sim	Antigo	1
Não contém	Sim	Antigo	0
Não contém	Sim	Antigo	0

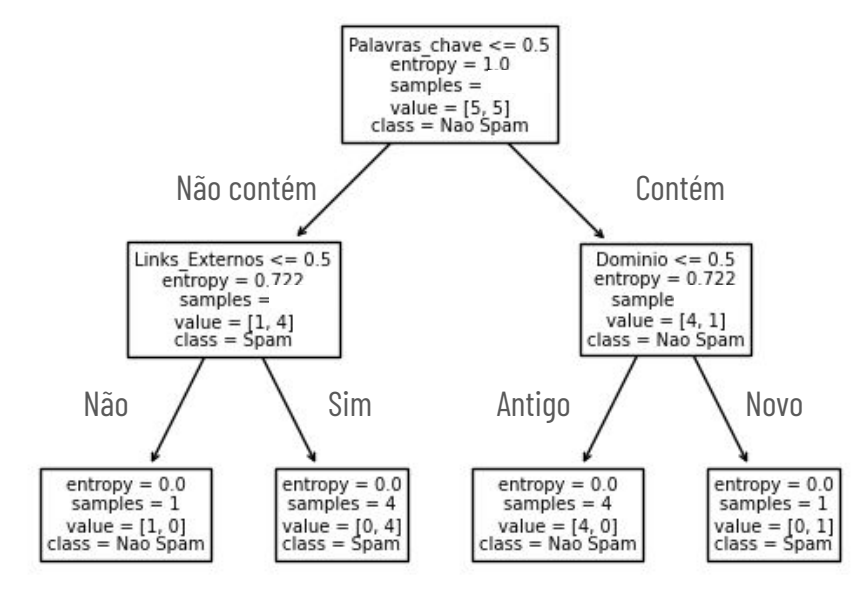

Aplicando sobre uma amostra

- **Testando novo exemplo**: ***Palavras-chave***: *contém*; ***links externos***: *sim*; ***domínio***: *novo*; ***spam***: *1*

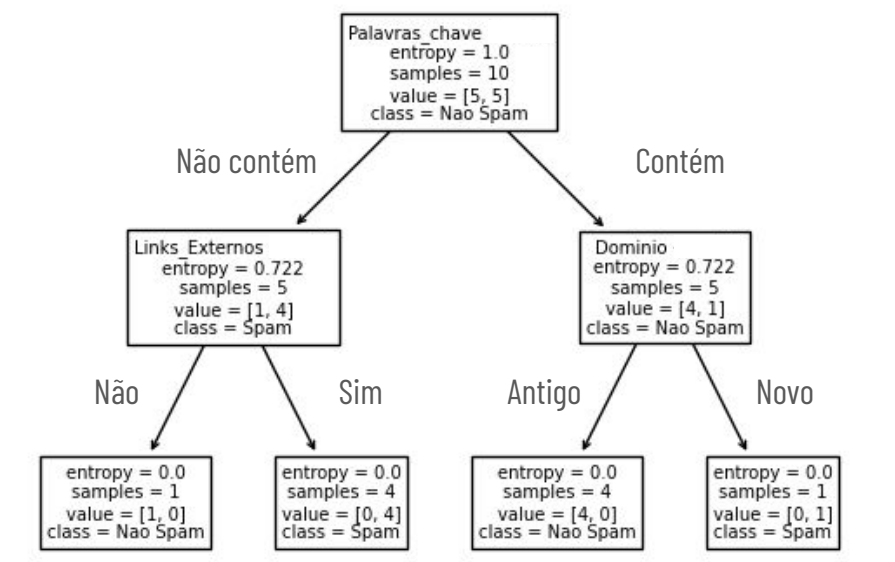

No meio do caos dos dados, queremos encontrar a pureza.

Medidas de Impureza

$$p_1 = \frac{\text{no. exemplos positivos}}{\text{no. exemplos totais}} \rightarrow \frac{5}{10} = 0.5$$

- Temos **duas classes** na variável alvo
- Em todo conjunto, temos uma alta **Impureza**
  - Dos 10 exemplos
  - 5 são da classe positiva (spam)
  - 5 da classe negativa (não é spam)
- Relação entre as classes (p1)
- **0.5 é a relação de maior impureza possível**

Medida de Impureza

- Temos exatamente metade dos dados como classe positiva e metade como classe negativa
- **Se o conjunto de dados tivesse 100% positivos ou negativos, seria considerado PURO**.
- **A Árvore de Decisão tenta encontrar decisões puras**

E como medir o nível de impureza?

- **Entropia**
  - Começa no zero, sobe até o valor máximo de um e volta para zero

$$H(S) = -\sum_{i=1}^{c} p_i \log_2(p_i)$$

- p_i = proporção da classe ***i*** no conjunto ***S***
- log_2 = logaritmo na base 2
- A soma percorre todas as classes
- **Importante saber que:**
  - $0 \leq H(S) \leq \log_2(c)$, onde c é o número de classes

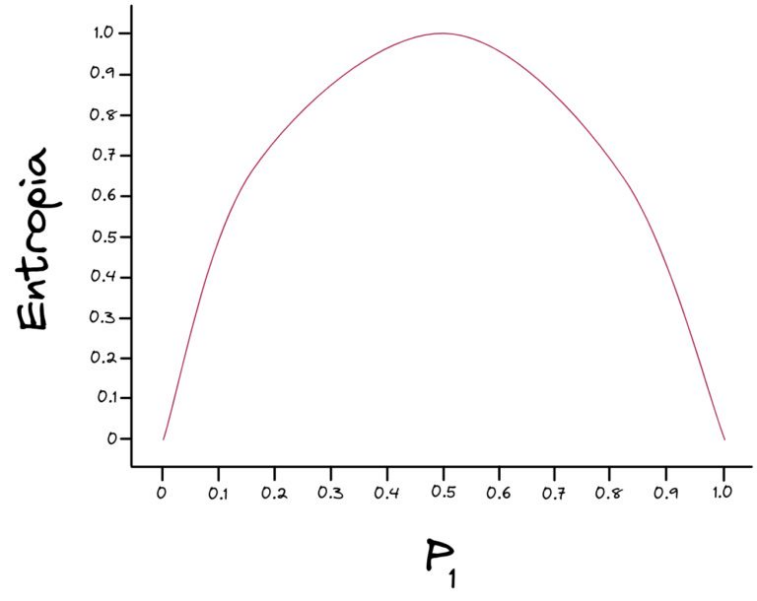

Entropia: Exemplo

- Se temos **6** exemplos, sendo **2** da classe positiva
- Em outro **subconjunto** também temos **6** exemplos, mas **5** da classe positiva:

$$p_1 = \frac{\text{no. exemplos positivos}}{\text{no. exemplos totais}} \rightarrow \frac{2}{6} = 0.33$$

$$p_1 = \frac{\text{no. exemplos positivos}}{\text{no. exemplos totais}} \rightarrow \frac{5}{6} = 0.83$$

$$p_1 = \frac{5}{10} \rightarrow H(p_1) = 1.0$$

$$p_1 = \frac{2}{6} \rightarrow H(p_1) = 0.92$$

$$p_1 = \frac{5}{6} \rightarrow H(p_1) = 0.65$$

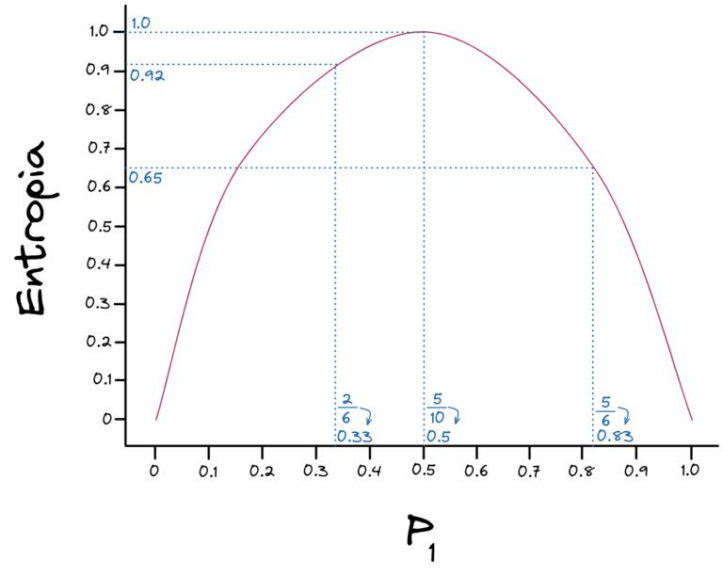

Medida de Impureza

Palavras-chave	Links Externos	Dominio	Spam
Contem	Sim	Novo	1
Nao contem	Nao	Novo	1
Nao contem	Sim	Antigo	0
Contem	Nao	Novo	0
Contem	Sim	Novo	1
Contem	Sim	Antigo	1
Nao contem	Nao	Antigo	0
Contem	Sim	Antigo	1
Não contém	Sim	Antigo	0
Não contém	Sim	Antigo	0

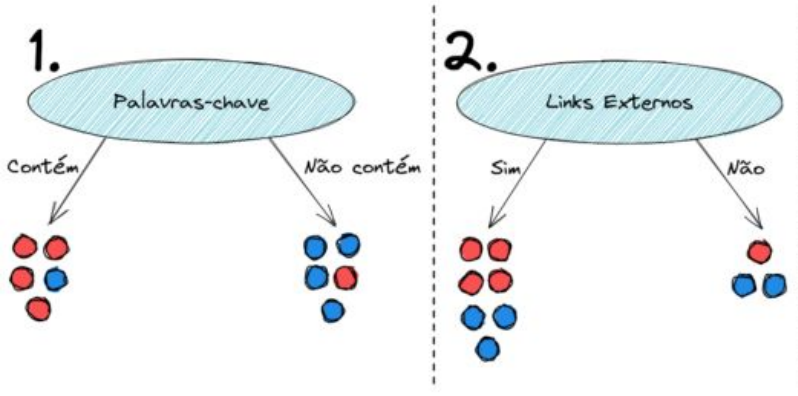

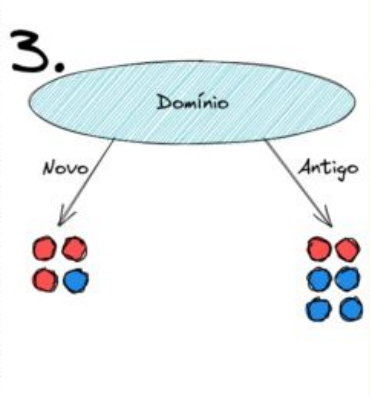

Entropia: Exercício

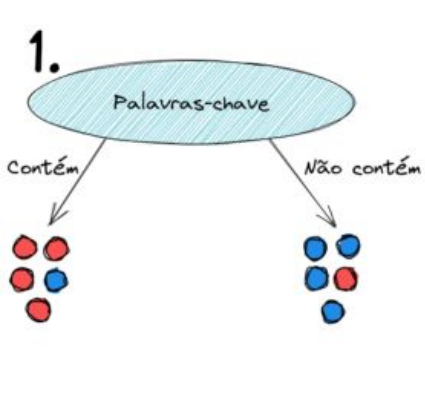

$$H(S) = -\sum_{i=1}^{c} p_i \log_2(p_i)$$

- Calcular a **proporção de classes e a entropia para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e entropia para cada ramo** (subconjunto) contém e não-contém

Entropia: Resolução

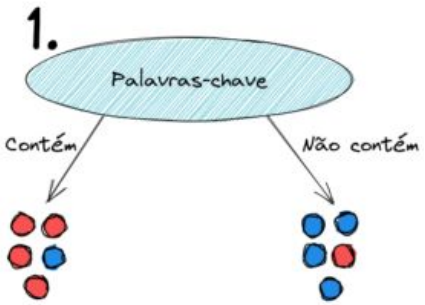

- Calcular a **proporção de classes e a entropia para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e entropia para cada ramo** (subconjunto) contém e não-contém

$$\log_2(0.8) \approx -0.32$$

$$\log_2(0.2) \approx -2.32$$

$$p(Spam) = \frac{5}{10} = 0.5$$

$$p(NãoSpam) = \frac{5}{10} = 0.5$$

$$H(S) = -0.5\log_2(0.5) - 0.5\log_2(0.5)$$

$$H(S) = -0.5(-1) - 0.5(-1)$$

$$H(S) = 1$$

$$p(Spam) = \frac{4}{5} = 0.8$$

$$p(NãoSpam) = \frac{1}{5} = 0.2$$

$$H = -0.8\log_2(0.8) - 0.2\log_2(0.2)$$

$$H = -[0.8(-0.32) + 0.2(-2.32)]$$

$$H = -[-0.256 - 0.464]$$

$$H \approx 0.72$$

$$p(Spam) = 0.2$$

$$p(NãoSpam) = 0.8$$

$$H = -0.8\log_2(0.8) - 0.2\log_2(0.2)$$

$$H = -[0.8(-0.32) + 0.2(-2.32)]$$

$$H = -[-0.256 - 0.464]$$

$$H \approx 0.72$$

Entropia: Exercício

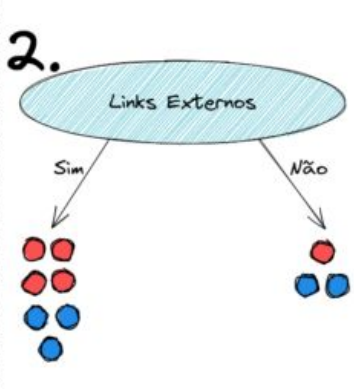

- Calcular a **proporção de classes e a entropia para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e entropia para cada ramo** (subconjunto) contém e não-contém

Entropia: Exercício

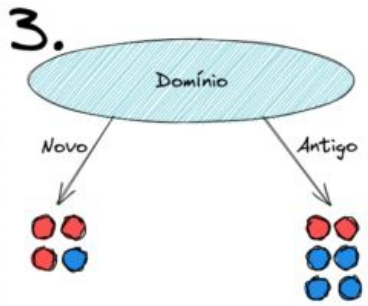

- Calcular a **proporção de classes e a entropia para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e entropia para cada ramo** (subconjunto) contém e não-contém

Informação não é o que você sabe, é o quanto de dúvida você consegue eliminar.

Ganho de informação

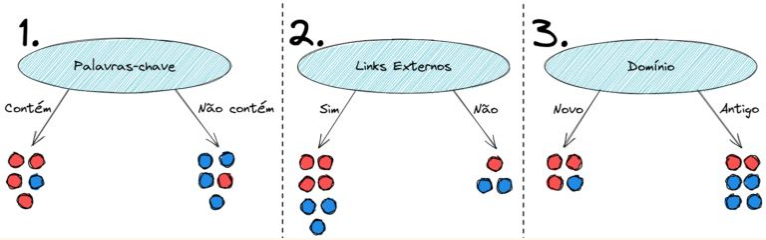

- Mede quanto a incerteza (entropia) diminui após dividir os dados por um atributo

$$Gain(S, A) = H(S) - \sum \frac{|S_v|}{|S|} H(S_v)$$

  - H(S) é a entropia antes da divisão
  - H(Sv) é a entropia após a divisão
  - Escolhemos o atributo com **maior ganho**

Calculando o Ganho de informação

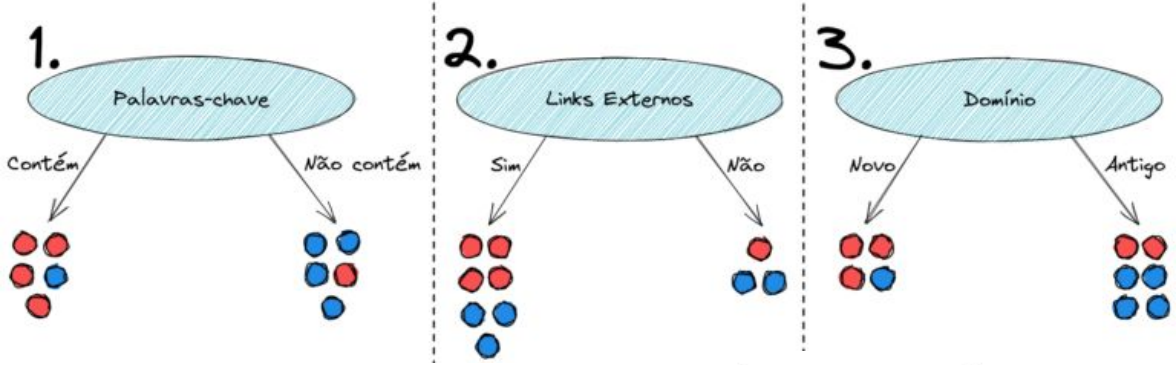

$$Gain(S, A) = H(S) - \sum \frac{|S_v|}{|S|} H(S_v)$$

$p_1 = \frac{4}{5} = 0.8$ $\quad$ $p_1 = \frac{1}{5} = 0.2$

$H(0.8) = 0.72$ $\quad$ $H(0.2) = 0.72$

$$\left(\frac{5}{10}H(0.8) + \frac{5}{10}H(0.2)\right)$$

$$H(0.5) - \left(\frac{5}{10}H(0.8) + \frac{5}{10}H(0.2)\right) = 0.28$$

$p_1 = \frac{4}{7} = 0.57$ $\quad$ $p_1 = \frac{1}{3} = 0.33$

$H(0.57) = 0.99$ $\quad$ $H(0.33) = 0.92$

$$\left(\frac{7}{10}H(0.57) + \frac{3}{10}H(0.33)\right)$$

$$H(0.5) - \left(\frac{7}{10}H(0.57) + \frac{3}{10}H(0.33)\right) = 0.03$$

$p_1 = \frac{3}{4} = 0.75$ $\quad$ $p_1 = \frac{2}{6} = 0.33$

$H(0.75) = 0.81$ $\quad$ $H(0.33) = 0.92$

$$\left(\frac{4}{10}H(0.75) + \frac{6}{10}H(0.33)\right)$$

$$H(0.5) - \left(\frac{4}{10}H(0.57) + \frac{6}{10}H(0.33)\right) = 0.12$$

A melhor decisão

- A **melhor decisão** a ser tomada será a que nos der um **valor maior de Ganho de Informação**
- **Aplicar** esse algoritmo **de forma recursiva**, construindo assim as **próximas ramificações** da mesma forma sobre os subconjuntos de dados

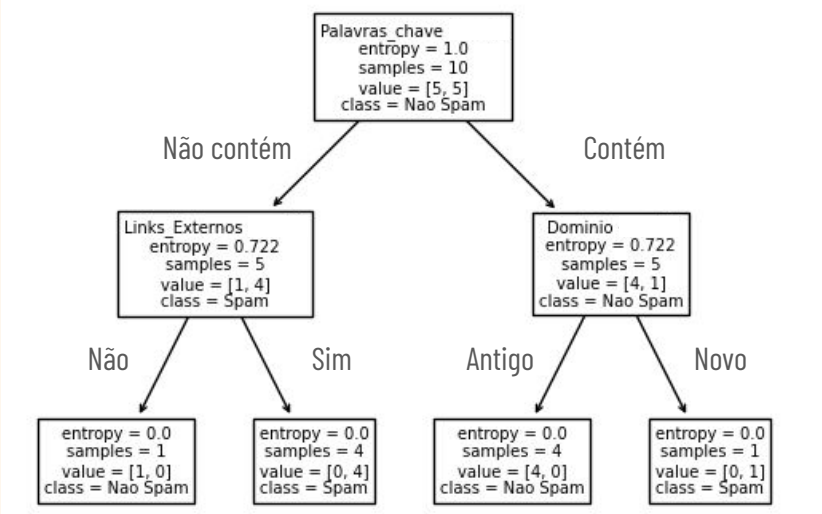

Coeficiente de Gini

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

- Mede o grau de mistura de classes em um nó
- Quanto mais puro (ou homogêneo) for um nó, menor será o Gini

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

- Durante a construção da árvore:
  - Calculamos o Gini de cada divisão
  - **Escolhemos a que gera menor impureza média ponderada, podendo selecionar diferentes combinações de nós**

Coeficiente de Gini: Resolução

1.

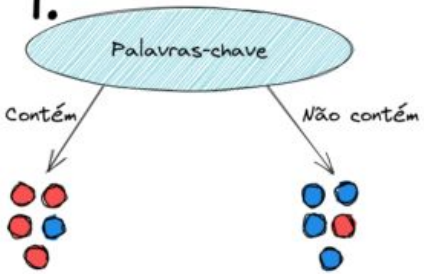

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini(S) = 1 - (0.5^2 + 0.5^2)$$

$$Gini(S) = 1 - (0.25 + 0.25)$$

$$Gini(S) = 0.5$$

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$Gini_{novo} = \frac{5}{10}(0.32) + \frac{5}{10}(0.32)$$

$$= 0.32$$

$$\Delta Gini = 0.5 - 0.32 = 0.18$$

Coeficiente de Gini: Resolução

1.

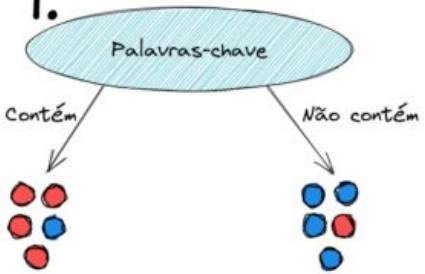

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini(S) = 1 - (0.5^2 + 0.5^2)$$

$$Gini(S) = 1 - (0.25 + 0.25)$$

$$Gini(S) = 0.5$$

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$Gini_{novo} = \frac{5}{10}(0.32) + \frac{5}{10}(0.32)$$

$$= 0.32$$

$$\Delta Gini = 0.5 - 0.32 = 0.18$$

Coeficiente de Gini: Resolução

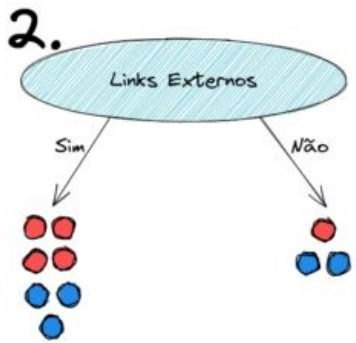

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

Coeficiente de Gini: Resolução

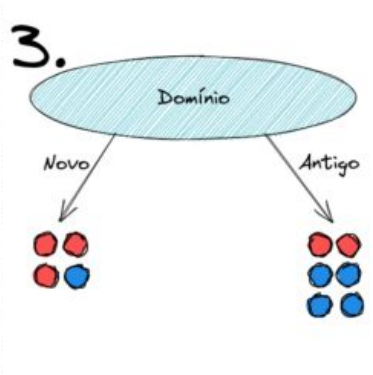

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

Entropia vs Gini

- Geralmente a árvore construída com Entropia ou Gini é muito parecida
- **Entropia**
  - Baseada na teoria da informação
  - Mais sensível a mudanças próximas de 0.5
- **Gini**
  - Mede probabilidade de erro de classificação aleatória
  - Computacionalmente mais simples

Exercício

Tempo	Umidade	Vento	Praticar Esporte
Ensolarado	Alta	Fraco	Não
Ensolarado	Alta	Forte	Não
Nublado	Alta	Fraco	Sim
Chuvoso	Baixa	Fraco	Sim
Chuvoso	Alta	Forte	Não

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - Capítulo 6

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb