C.E.S.A.R school

Aprendizado de Máquina

Árvores de Decisão

2026 | Fevereiro

Relembrando...

Entropia e Ganho de informação

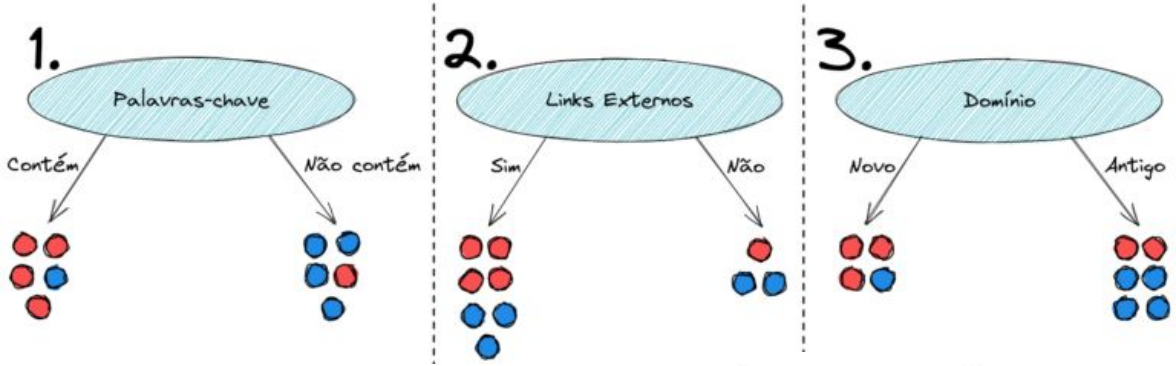

$$H(S) = -\sum_{i=1}^{c} p_i \log_2(p_i)$$

$$Gain(S, A) = H(S) - \sum \frac{|S_v|}{|S|} H(S_v)$$

$p_1 = \frac{4}{5} = 0.8$ $\quad$ $p_1 = \frac{1}{5} = 0.2$

$H(0.8) = 0.72$ $\quad$ $H(0.2) = 0.72$

$$\left(\frac{5}{10}H(0.8) + \frac{5}{10}H(0.2)\right)$$

$$H(0.5) - \left(\frac{5}{10}H(0.8) + \frac{5}{10}H(0.2)\right) = 0.28$$

$p_1 = \frac{4}{7} = 0.57$ $\quad$ $p_1 = \frac{1}{3} = 0.33$

$H(0.57) = 0.99$ $\quad$ $H(0.33) = 0.92$

$$\left(\frac{7}{10}H(0.57) + \frac{3}{10}H(0.33)\right)$$

$$H(0.5) - \left(\frac{7}{10}H(0.57) + \frac{3}{10}H(0.33)\right) = 0.03$$

$p_1 = \frac{3}{4} = 0.75$ $\quad$ $p_1 = \frac{2}{6} = 0.33$

$H(0.75) = 0.81$ $\quad$ $H(0.33) = 0.92$

$$\left(\frac{4}{10}H(0.75) + \frac{6}{10}H(0.33)\right)$$

$$H(0.5) - \left(\frac{4}{10}H(0.57) + \frac{6}{10}H(0.33)\right) = 0.12$$

A melhor decisão

- A **melhor decisão** a ser tomada será a que nos der um **valor maior de Ganho de Informação**
- **Aplicar** esse algoritmo **de forma recursiva**, construindo assim as **próximas ramificações** da mesma forma sobre os subconjuntos de dados

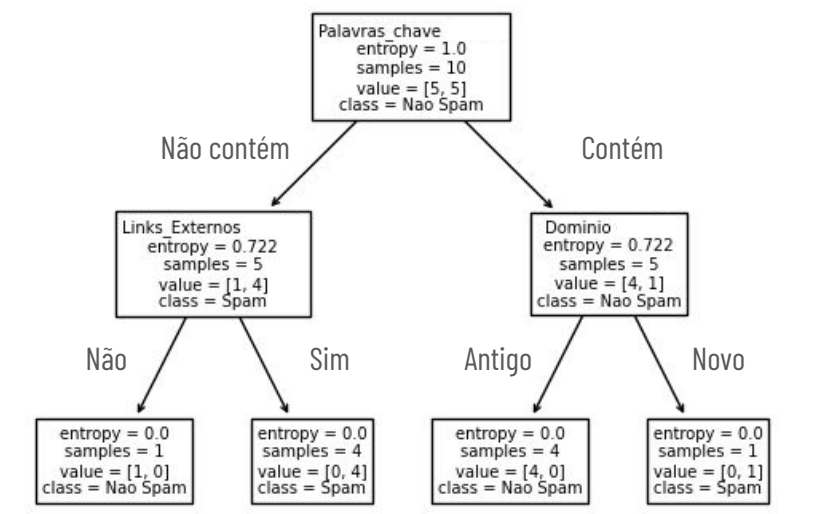

Coeficiente de Gini

- Mede o grau de mistura de classes em um nó
- **Quanto mais puro** (ou homogêneo) for um nó, **menor será o Gini**
- Durante a construção da árvore:
  - Calculamos o Gini antes da divisão e depois de cada divisão (filhos)
  - A diferença entre eles permite avaliar a redução da impureza

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$\Delta Gini = Gini_{antes} - \sum_{filhos} \frac{n_{filho}}{n_{total}} Gini_{filho}$$

Coeficiente de Gini: Resolução

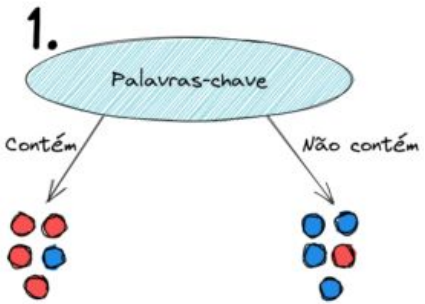

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave), antes da divisão
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém, após a divisão

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$\Delta Gini = Gini_{antes} - \sum_{filhos} \frac{n_{filho}}{n_{total}} Gini_{filho}$$

Coeficiente de Gini: Resolução

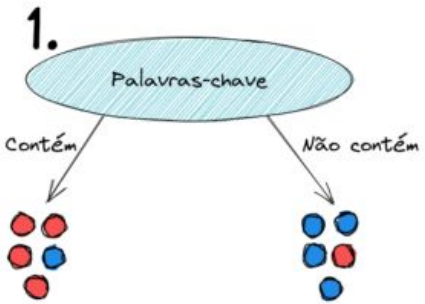

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

Antes da divisão...

$$Gini(S) = 1 - (0.5^2 + 0.5^2)$$

$$Gini(S) = 1 - (0.25 + 0.25)$$

$$Gini(S) = 0.5$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$p(1) = 0.8, \quad p(0) = 0.2$$

$$Gini = 1 - (0.8^2 + 0.2^2)$$

$$Gini = 0.32$$

$$Gini_{novo} = \frac{5}{10}(0.32) + \frac{5}{10}(0.32)$$

$$= 0.32$$

$$\Delta Gini = 0.5 - 0.32 = 0.18$$

Coeficiente de Gini: Resolução

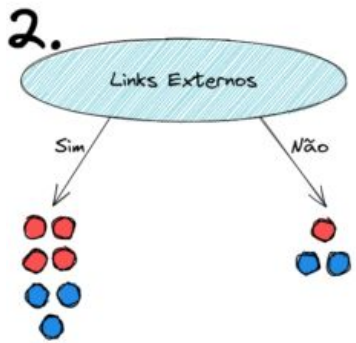

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$\Delta Gini = Gini_{antes} - \sum_{filhos} \frac{n_{filho}}{n_{total}} Gini_{filho}$$

Coeficiente de Gini: Resolução

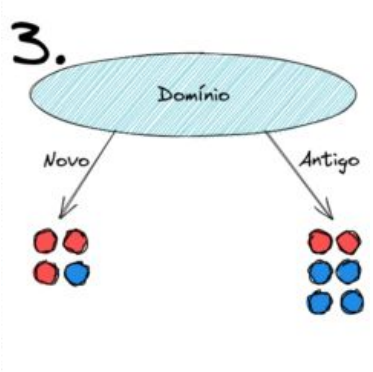

- Calcular a **proporção de classes e Gini para o conjunto** (todo o conjunto palavras chave)
- Calcular a **proporção e Gini para cada ramo** (subconjunto) contém e não-contém

$$Gini = 1 - \sum_{i=1}^{C} p_i^2$$

$$Gini_{divisão} = \frac{n_{esq}}{n} \cdot Gini_{esq} + \frac{n_{dir}}{n} \cdot Gini_{dir}$$

$$\Delta Gini = Gini_{antes} - \sum_{filhos} \frac{n_{filho}}{n_{total}} Gini_{filho}$$

Entropia vs Gini

- **Entropia**
  - Baseada na teoria da informação
  - Mais sensível a mudanças próximas de 0.5
- **Gini**
  - Mede probabilidade de erro de classificação aleatória
  - **Computacionalmente mais simples**
- Qual usar?
  - **Geralmente a árvore construída com Entropia ou Gini é muito parecida**

Se deixarmos a árvore crescer até classificar 100% corretamente os dados de treino... ela ficou perfeita?

Overfitting e underfitting

- Em overfitting se aprende os padrões reais, mas também aprende o **ruído**
  - Fica **excelente no treino**, mas fica **ruim em dados novos**
  - Árvores de Decisão são propensas porque...
    - Podem dividir infinitamente
    - Criam nós até que:
      - **cada folha tenha 1 exemplo**
      - ou todos os exemplos sejam puros
- E o underfitting?

Como controlar overfitting?

- Profundidade máxima (**max_depth**)
- Número mínimo de amostras para dividir (**min_samples_split**)
  - Impede divisão quando há poucos dados
- Número mínimo de amostras na folha (**min_samples_leaf**)
  - Evita folhas com 1 exemplo só
- E o underfitting?

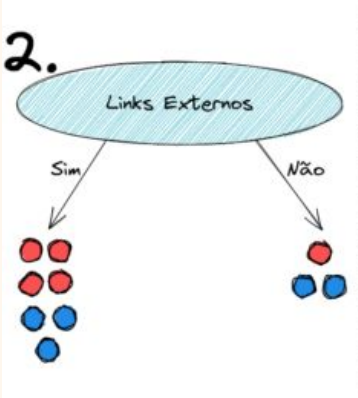

E quando o problema for regressão?

Regressão

- A árvore escolhe a divisão que **minimiza o erro quadrático dentro dos nós**
  - Cada folha prevê a média dos valores no nó $\sum (y_i - \bar{y})^2$
  - Queremos que os valores dentro do nó sejam o mais próximos possível da média
- **Isso é equivalente a minimizar a variância**

Regressão

- Divide os valores dos atributos
- Para cada divisão candidata:
  - Divide os dados em dois grupos
  - Calcula a média do y em cada grupo
  - Calcula o erro quadrático total
- A melhor divisão é aquela que:
  - Minimiza o erro quadrático total após a divisão

x_1	x_2	x_3	y
70	2	5	300
80	3	10	350
120	4	2	600
60	2	20	250

Overfitting em regressão

- Se deixar crescer muito:
  - Cada folha pode conter 1 exemplo
  - A previsão vira exatamente o valor observado
    - Erro de treino = 0
    - Generalização = ruim

Questões (Página 186)

- Qual é a profundidade aproximada de uma Árvore de Decisão treinada (sem restrições) em um conjunto de treinamento com um milhão de instâncias?
- A impureza Gini de um nó é geralmente menor ou maior que a de seu nó pai? Ela é geralmente menor/maior ou sempre menor/maior?
- Se uma Árvore de Decisão estiver sofrendo overfitting no conjunto de treino, é uma boa ideia diminuir o max_depth?
- Se uma Árvore de Decisão estiver sofrendo underfitting no conjunto de treino, é uma boa ideia escalar os atributos de entrada?

Respirem fundo: para a prática de hoje a única coisa que vai sofrer para calcular logaritmo é a CPU, não o pulso de vocês!

Mas só por hoje. ;)

Prática

- Leia o conjunto de dados Iris
- Defina os conjuntos de treino e teste de forma estratificada
- Avalie variações de hiperparametros
  - Entropia vs coeficiente de Gini
  - Profundidade máxima (**max_depth**)
  - Número mínimo de amostras para dividir (**min_samples_split**)
  - Número mínimo de amostras na folha (**min_samples_leaf**)

Lista de exercícios

- Google Classroom

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - Capítulo 6

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb