C.E.S.A.R school

Aprendizado de Máquina

Ensemble Learning

2026 | Fevereiro

Vox populi, vox Dei

Ensembles ou comitês

- Durante o treinamento de um comitê, o objetivo é **construir uma coleção de preditores que, juntos, produzem uma predição melhor do que cada um separadamente**
- A fronteira de decisão correspondente a um modelo de comitê pode ser aproximada por meio de uma combinação apropriada dos diferentes preditores (classificadores ou regressores)

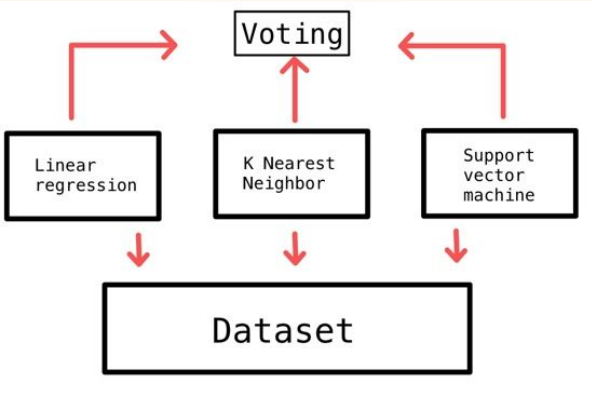

Ensemble: Superfície de decisão

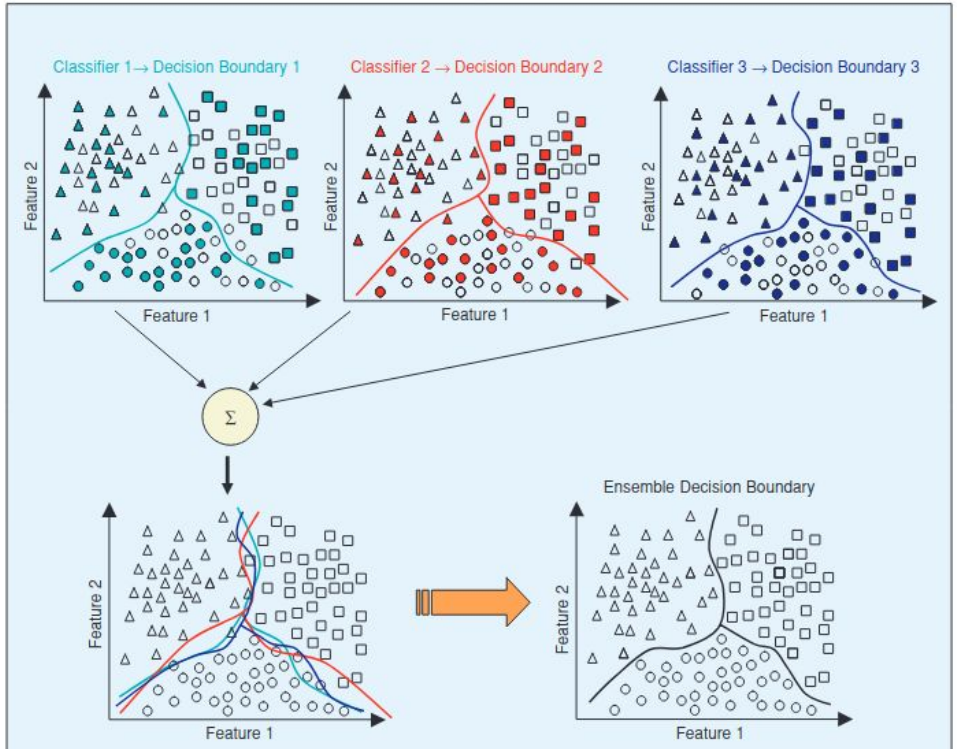

Figure 3. Combining classifiers that are trained on different subsets of the training data.

Ensemble: Funcionamento

- Modelos diferentes são treinados em conjuntos de dados variados
- As previsões dos modelos são combinadas (por votação, média, entre outros) para obter uma resposta final
- A combinação ajuda a **mitigar fraquezas de cada modelo isolado**, criando uma solução mais confiável
- **Destacam-se** dois tipos clássicos de comitês: **Bagging e Boosting**

Bagging

- **Bagging**: é um comitê que treina (fit) os modelos em subconjuntos **aleatórios** do conjunto de dados original e, em seguida, **agrega suas previsões individuais por votação ou por média** para formar uma previsão final

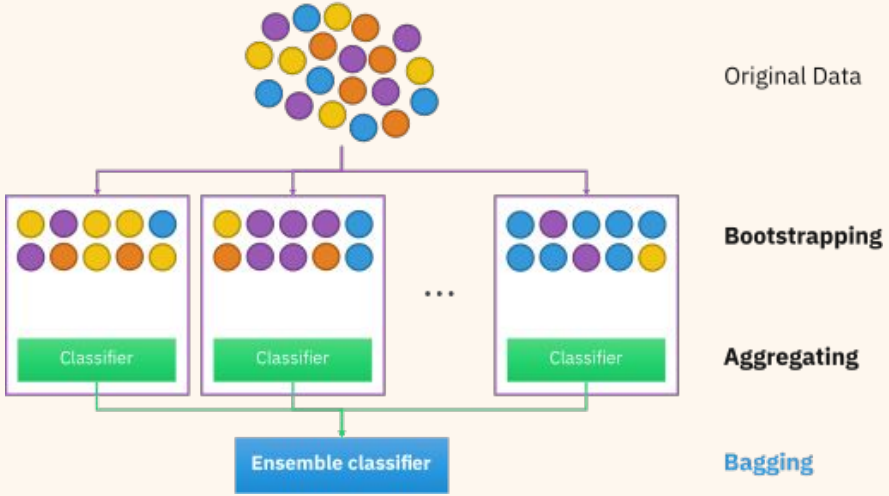

Bagging

- O Bagging pode normalmente ser usado como uma forma de reduzir a variância de um estimador (por exemplo, uma árvore de decisão), introduzindo aleatoriedade por meio do procedimento na construção dos datasets
- Cria um **efeito de suavização nas previsões, onde erros extremos de modelos individuais são compensados pelos acertos de outros**
- Para a **classificação**, aplica-se uma votação entre as predições dos modelos individuais. Para **regressão**, usa-se a média

Bagging

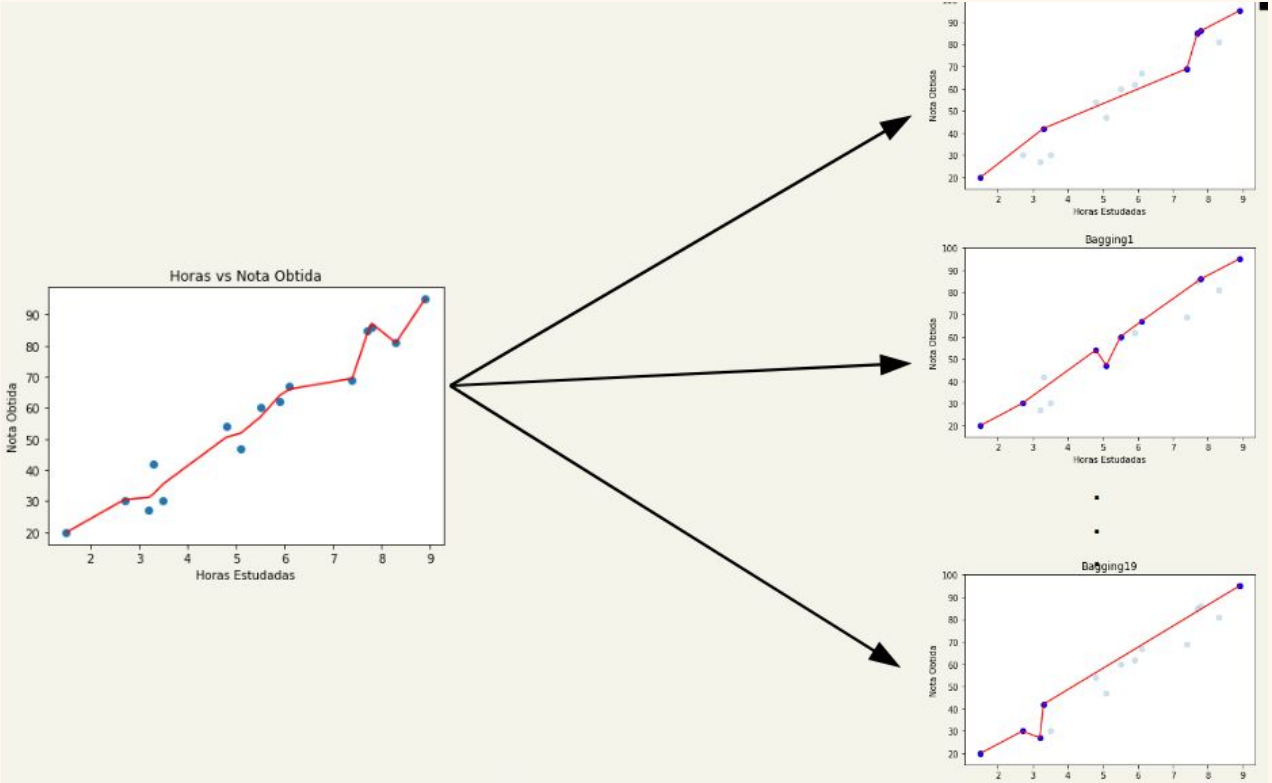
Horas vs Nota Obtida
Nota Obtida
Horas Estudadas
Bagging1
Bagging19

Bagging

- **Random Forest** é um classificador que é um um **caso particular de bagging**. Os subconjunto de dados são gerados a partir de:
  - bootstrap do conjunto de treinamento (com reposição) e
  - subconjuntos aleatórios de atributos (features)
- Devido à seleção aleatória de atributos, as árvores são mais independentes (i.e., diferentes) umas das outras quando comparado ao bagging
- **Importante:** A seleção aleatória de features aparece no Random Forest, não no bootstrapping

Prática

- Leia o conjunto de dados Iris
- Defina os conjuntos de treino e teste de forma estratificada
- Avalie variações de ensembles (voting)
- Avalie variações para o Random Forest

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - **Capítulo 7**

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb