C.E.S.A.R school

Aprendizado de Máquina

Random Forest

2026 | Março

Enquanto uma árvore decide, a floresta vota.

Já sabemos que...

- **Bagging**: comitê que treina os modelos em subconjuntos **aleatórios** do conjunto de dados original e, em seguida, **agrega suas previsões individuais por votação ou por média**

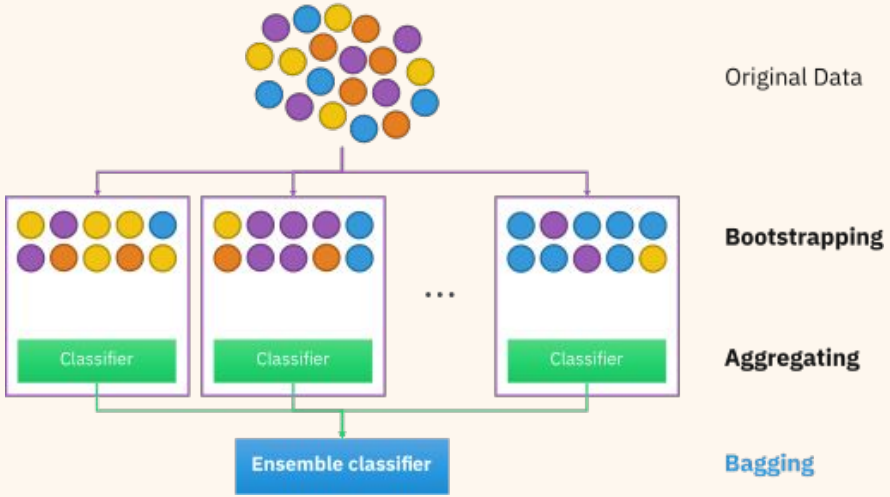

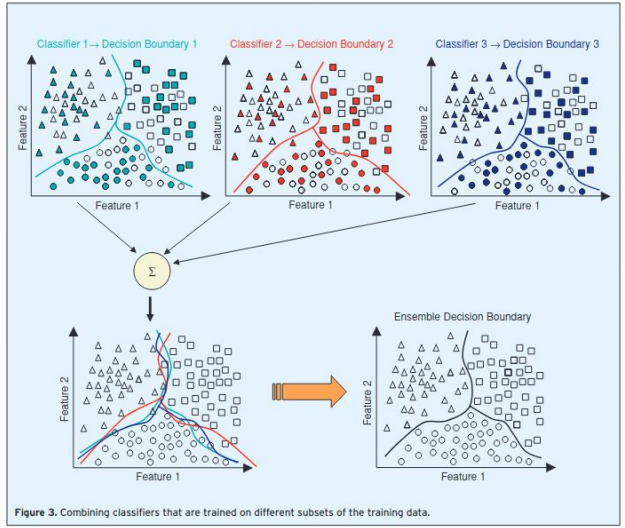

Figure 3. Combining classifiers that are trained on different subsets of the training data.

Random Forest

- **Random Forest** é um **caso particular de bagging**. Os subconjunto de dados são gerados a partir de:
  - bootstrap do conjunto de treinamento (com reposição) e
  - subconjuntos aleatórios de atributos (features)
- Devido à **seleção aleatória de atributos**, **as árvores são mais independentes umas das outras** quando comparado ao bagging
- **Importante:** A seleção aleatória de features aparece no Random Forest!

Overfitting e underfitting

- Em uma Decision Tree, **árvores profundas podem levar ao overfitting**
- **No Random Forest, esse risco é reduzido**, porque:
  - cada árvore **vê apenas uma amostra bootstrap** dos dados
  - cada divisão usa apenas um **subconjunto de features**
  - **a previsão final é uma agregação de várias árvores**
- Random Forest é **menos sensível a overfitting**

Out-of-bag

- Os out-of-bag (OOB) são os exemplos que não foram selecionados no bootstrap para treinar um determinado modelo
- Funcionam como conjunto de validação do modelo
- Cada árvore é treinada com apenas ~67% dos dados, os ~33% restantes funcionam como um conjunto de teste para aquela árvore

Feature importance

- Possível estimar **quais variáveis mais contribuíram para as decisões** do modelo
- O algoritmo **calcula** a importância de cada feature **com base na redução de impureza gerada pelas divisões nas árvores da floresta**
  - Identificar quais variáveis mais influenciam as previsões
  - Ajudar na interpretação do modelo
  - Apoiar seleção ou redução de features
- Mas... **alta importância não significa causalidade, apenas que a variável foi útil para melhorar as divisões das árvores.**

Feature importance

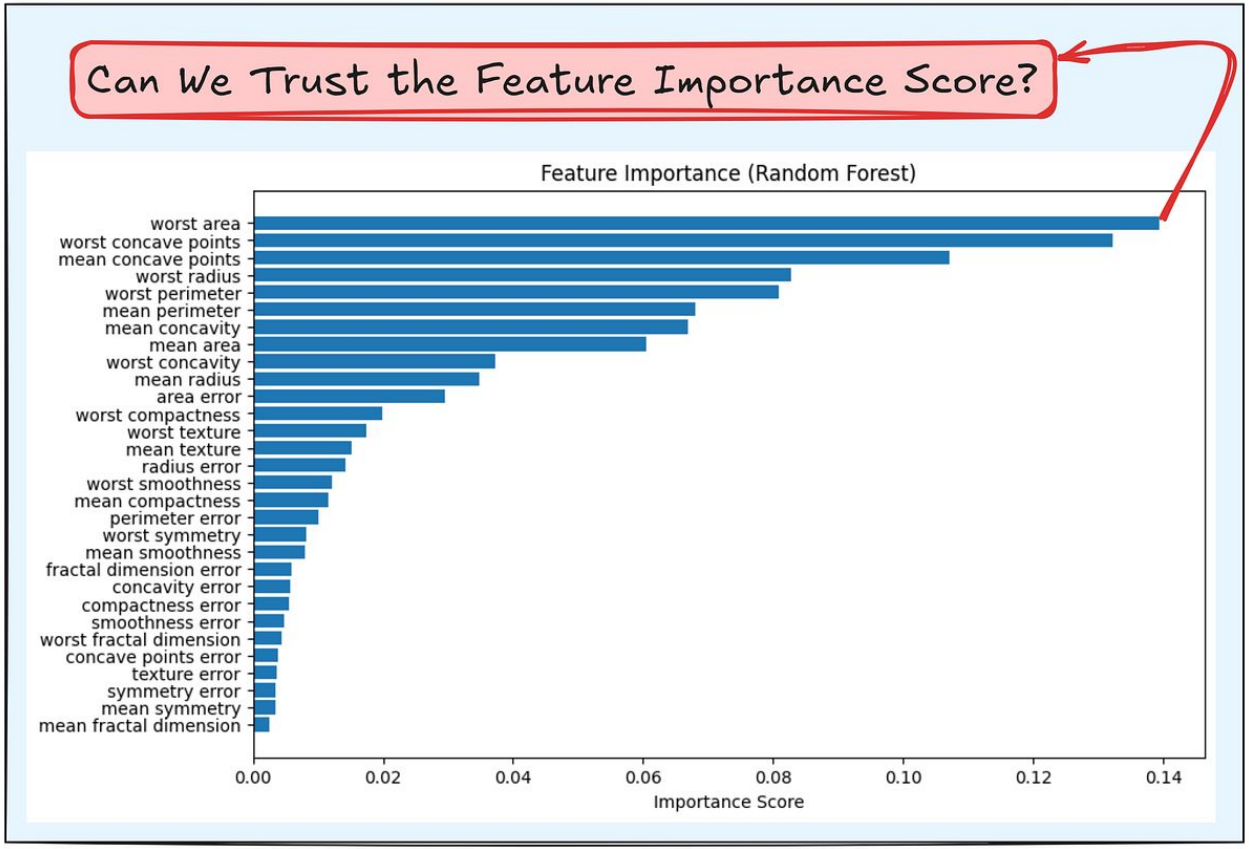

Prática

- Classificação de dígitos manuscritos
  - 70k imagens (60k treino/10k teste) de dígitos manuscritos (0-9) em tons de cinza
  - São normalizados e centralizados
  - Medindo pixels 28x28

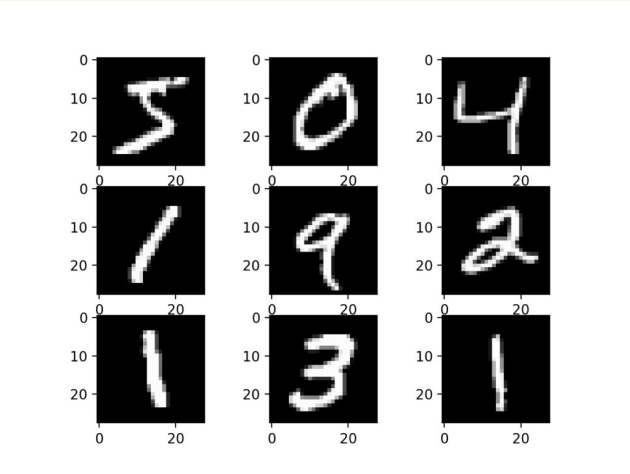

Prática

- Classificação de peças de roupas
  - 70k imagens (60k treino/10k teste) de peças de roupas em tons de cinza
  - São normalizados e centralizados
  - Medindo pixels 28x28

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - **Capítulo 7**

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb