C.E.S.A.R school

Aprendizado de Máquina

Avaliando modelos preditivos

2026 | Março

A Ilusão do Placar: Por que 99% de acerto pode ser um desastre no mundo real?

Matriz de confusão

- Permite **visualizar os erros de classificação do modelo durante os testes**
- Possível verificar se o modelo tende a favorecer uma classe específica e quais ele tem mais problemas para classificar

Matriz de confusão

- Possível verificar se o modelo tende a favorecer uma classe específica e quais ele tem mais problemas para classificar
  - **Verdadeiro Positivo:** Quando o modelo classifica **corretamente** a classe Positiva como Positiva
  - **Verdadeiro Negativo**: Quando o modelo classifica **corretamente** a classe Negativa como Negativa

Matriz de confusão

- Possível verificar se o modelo tende a favorecer uma classe específica e quais ele tem mais problemas para classificar
  - **Falso Positivo**: Quando o modelo classifica **incorretamente** a classe Negativa como Positiva
    - O alarme toca, mas não há fogo. (Custo: Irritação e perda de tempo)
  - **Falso Negativo**: Quando classifica **incorretamente** a classe Positiva como Negativa
    - Há fogo, mas o alarme não toca. (Custo: Desastre total)

Matriz de confusão

Classes Reais

Predição	Positivo	Negativo
Positivo	Verdadeiro Positivo	Falso Positivo
Negativo	Falso Negativo	Verdadeiro Negativo

Matriz de confusão: implementação

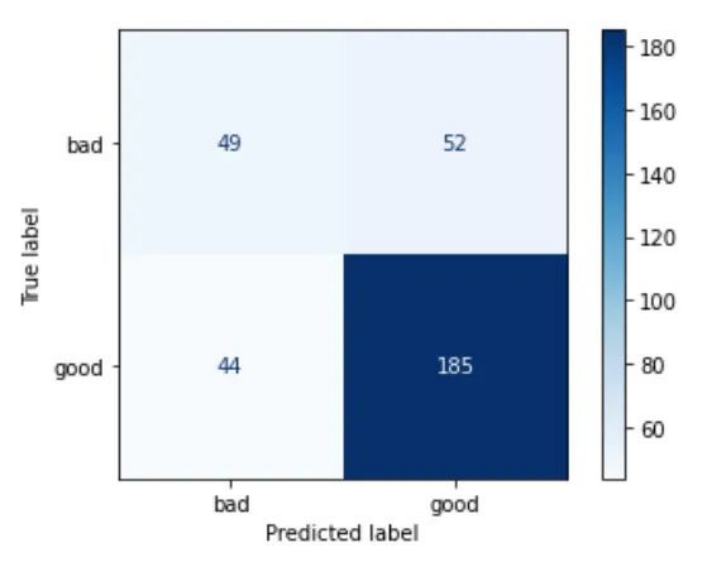


```
from sklearn.metrics import confusion_matrix
from sklearn.metrics import ConfusionMatrixDisplay
cm = confusion_matrix(y_val, y_val_predicted)
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['bad', 'good'])
```

Matriz de confusão: avaliação

- Com acurácia em torno de 71%
  - Boa parte dos exemplos são da classe **good**, fazendo com que o modelo chute exemplos **bad** para a mesma classe
  - **O que pode ter causado?**

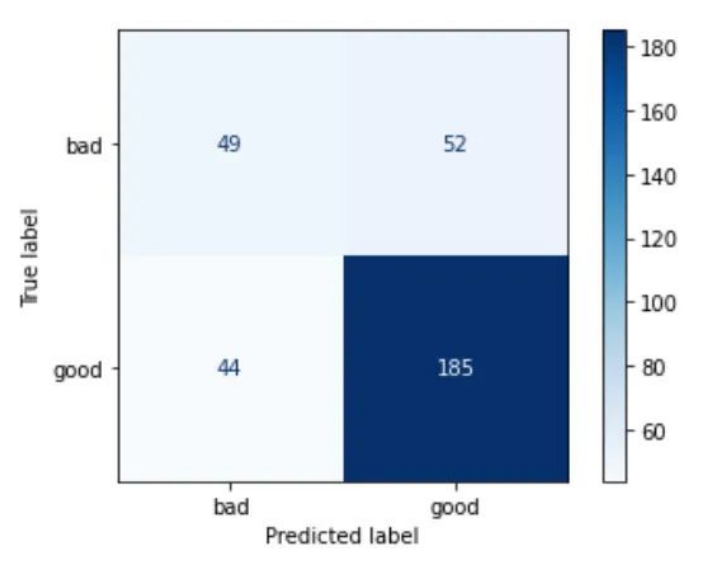

Matriz de confusão: avaliação

- Com acurácia em torno de 96,31%
  - Na **base de dados breast cancer** os resultados são bem melhores e o modelo parece conseguir classificar muito bem as classes
  - **O que pode ter causado?**

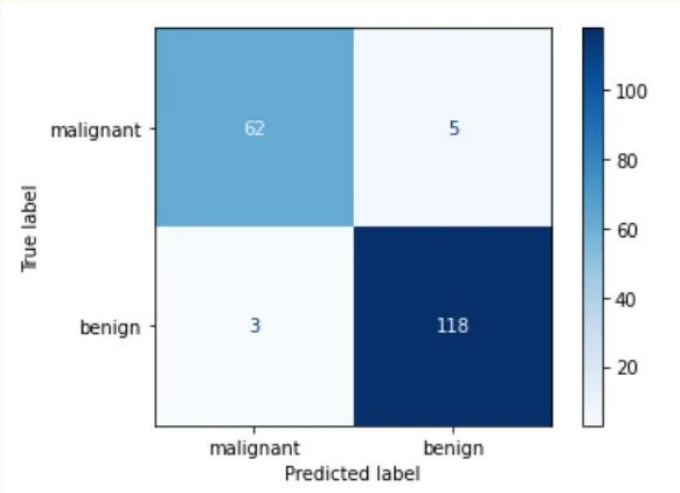

Acurácia: A métrica que mais engana noob.

Acurácia

- A acurácia da classificação é a razão entre o número de acertos e o total de previsões feitas
  - Porcentagem de acertos do modelo

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

Acurácia

- Identifique os valores de TP, FP, TN, FN.
- Explique o impacto de ter muitos falsos positivos neste contexto

	Previsto Positivo	**Previsto Negativo**
Real Positivo	40	10
Real Negativo	20	30

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

Acurácia

- **Não é uma boa métrica em conjuntos de dados desbalanceados**
  - Ex.: Se tivermos um modelo com 700 exemplos de teste, sendo 679 para classe A e 21 para classe B, **o resultado seria 97% mesmo que erre todas da classe B**

Precisão

- Avalia o **quão preciso é o modelo com verdadeiros positivos em relação a falsos positivos**
  - **Boa métrica para avaliar quando os falsos positivos são perigosos para a solução**
  - Ex.: **Filtro de SPAM.** É melhor um spam chegar na caixa de entrada (Falso Negativo) do que um e-mail importante do chefe ir para o lixo (Falso Positivo).
  - Precisão permite analisar: **Qual a confiança de que 'Sim' é realmente 'Sim'?**

$$precisão = \frac{VP}{VP + FP}$$

Recall

- Recall (ou sensibilidade) avalia a **capacidade do modelo de identificar os verdadeiros positivos**
  - **Falsos negativos diminuem o recall** e podemos priorizar essa métrica quando falsos negativos geram um impacto grande na solução
  - Ex.: Diagnóstico de Câncer ou Fraude Bancária. **Você prefere investigar um alarme falso (FP) do que deixar um paciente doente ir para casa sem tratameto (FN)**

$$sensibilidade = \frac{VP}{VP + FN}$$

Especificidade

- Especificidade avalia a capacidade do modelo de **identificar corretamente os Verdadeiros Negativos**
- O princípio é que é **melhor soltar um culpado (Falso Negativo) do que condenar um inocente (Falso Positivo)**
- Modelo "cético": ele só marca como positivo se tiver muita certeza, para não rotular erroneamente quem é "saudável" ou "inocente"

$$\text{Especificidade} = \frac{TN}{TN + FP}$$

Especificidade vs Sensibilidade

- Recall (Sensibilidade)
  - É o caçador e não quer deixar passar nenhum positivo
- Especificidade
  - É o juri que não deseja condenar nenhum inocente (negativo) por engano

F1-score

- Avalia precisão e recall, permitindo encontrar um equilíbrio entre elas
  - **Quando falsos positivos e falsos negativos são igualmente importantes**

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

F1-score

- Avalia precisão e recall, permitindo encontrar um equilíbrio entre elas
  - **Quando falsos positivos e falsos negativos são igualmente importantes**

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

E em casos multiclasses?

- A acurácia é a soma da diagonal principal (total de acertos) dividida pelo total de amostras
- Para calcular a **Precisão** e o **Recall** de cada classe, isolamos uma por uma como sendo a classe positiva. Ex:
  - **Recall Macro**: É a média aritmética simples dos recalls de cada classe
  - **Recall Micro**: Agrega todos os acertos globais

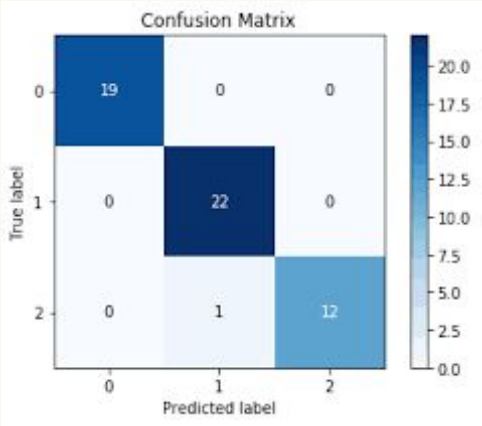

Exercício

- Um determinado modelo de um sistema de previsão do tempo, apresentou o desempenho descrito pela matriz de confusão.
  - Calcule a acurácia, precisão, recall e F1-score do modelo

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

$$precisão = \frac{VP}{VP + FP}$$

$$sensibilidade = \frac{VP}{VP + FN}$$

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

Predito

Real

	Choveu	Não-choveu
Choveu	40	15
Não-choveu	10	35

Curva ROC

- A **Curva ROC** (Receiver Operating Characteristic) avalia o desempenho do modelo em todos os limiares (thresholds) de classificação possíveis
- **Trade-off entre a Sensibilidade e a Taxa de Falsos Positivos (1–Especificidade)**
  - **Ajuste de um Detector de Metais**. Se aumentar a sensibilidade para garantir que nenhuma arma passe (Recall alto), o alarme tocará para chaves e fivelas de cinto (Falso Positivo alto/Especificidade baixa)
  - A curva ROC mostra exatamente esse cabo de guerra entre as métricas

$$TPR = \frac{TP}{TP + FN}$$ (sensibilidade)

$$FPR = \frac{FP}{FP + TN}$$ (1-especificidade)

Curva ROC

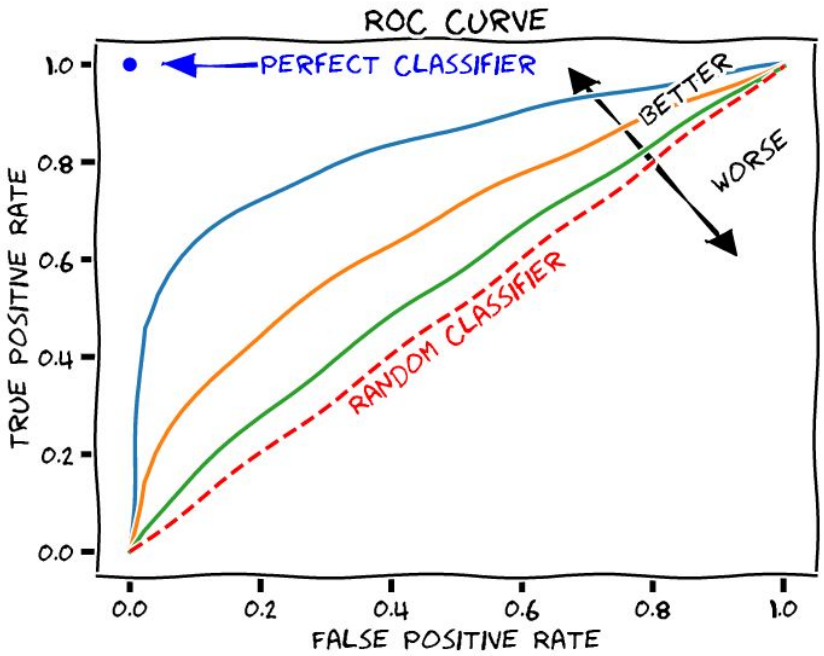

$$TPR = \frac{TP}{TP + FN}$$ (sensibilidade)

$$FPR = \frac{FP}{FP + TN}$$ (1-especificidade)

Calculando curva ROC

- Imagine que sua árvore classificou 6 clientes (se vão cancelar ou não a assinatura)
- Em vez de olhar apenas o "Sim/Não", olhamos a probabilidade (score) da folha

Cliente	Real (Classe)	Probabilidade da Árvore (Score)
1	Sim	0.90 (Folha A: 90% são 'Sim')
2	Sim	0.80 (Folha B: 80% são 'Sim')
3	Não	0.70 (Folha C: 70% são 'Sim')
4	Sim	0.40 (Folha D: 40% são 'Sim')
5	Não	0.20 (Folha E: 20% são 'Sim')
6	Não	0.10 (Folha F: 10% são 'Sim')

Calculando curva ROC

- Para cada probabilidade, podemos definir limiares
  - Ponto 1 (Limiar > 0.85)
  - Ponto 2 (Limiar > 0.50)
  - Ponto 3 (Limiar > 0.15)
- Posso usar mais?

Cliente	Real (Classe)	Probabilidade da Árvore (Score)
1	Sim	0.90 (Folha A: 90% são 'Sim')
2	Sim	0.80 (Folha B: 80% são 'Sim')
3	Não	0.70 (Folha C: 70% são 'Sim')
4	Sim	0.40 (Folha D: 40% são 'Sim')
5	Não	0.20 (Folha E: 20% são 'Sim')
6	Não	0.10 (Folha F: 10% são 'Sim')

Calculando curva ROC

- Calcular TPR e FPR para cada Ponto
  - Ponto 1 (Limiar > 0.85): Só o Cliente 1 é "Sim"
  - **VP = 1, FN = 2, FP = 0, VN = 3**
  - TPR (Recall) = 1 + 21 = 0,33
  - FPR (1–Esp.) = 0 + 30 = 0,00.
  - **Coordenada**: (0.00, 0.33)
- Ponto 2 (Limiar > 0.50)?
- Ponto 3 (Limiar > 0.15)?

Cliente	Real (Classe)	Probabilidade da Árvore (Score)
1	Sim	0.90 (Folha A: 90% são 'Sim')
2	Sim	0.80 (Folha B: 80% são 'Sim')
3	Não	0.70 (Folha C: 70% são 'Sim')
4	Sim	0.40 (Folha D: 40% são 'Sim')
5	Não	0.20 (Folha E: 20% são 'Sim')
6	Não	0.10 (Folha F: 10% são 'Sim')

Plotando a curva ROC

- **Eixo X (FPR):** O quanto estamos "mentindo" (Falsos Positivos)
- **Eixo Y (TPR):** O quanto estamos "achando" (Verdadeiros Positivos)

Plotando a curva ROC

- **Eixo X (FPR):** O quanto estamos "mentindo" (Falsos Positivos)
- **Eixo Y (TPR):** O quanto estamos "achando" (Verdadeiros Positivos)

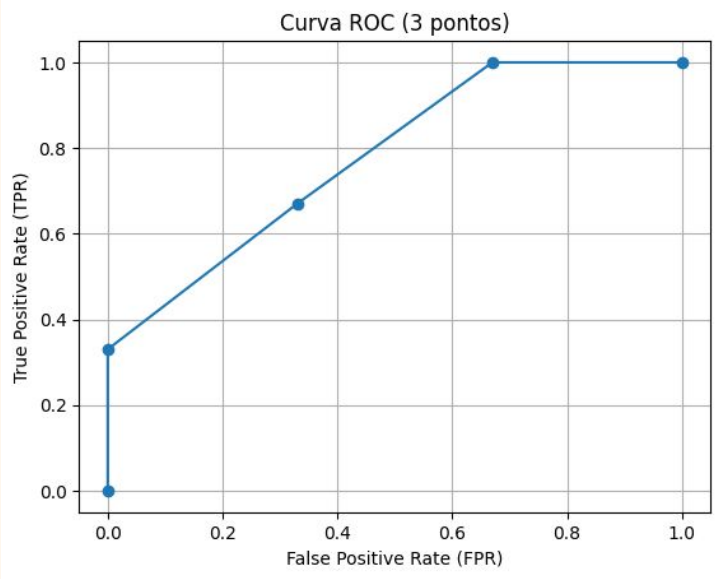

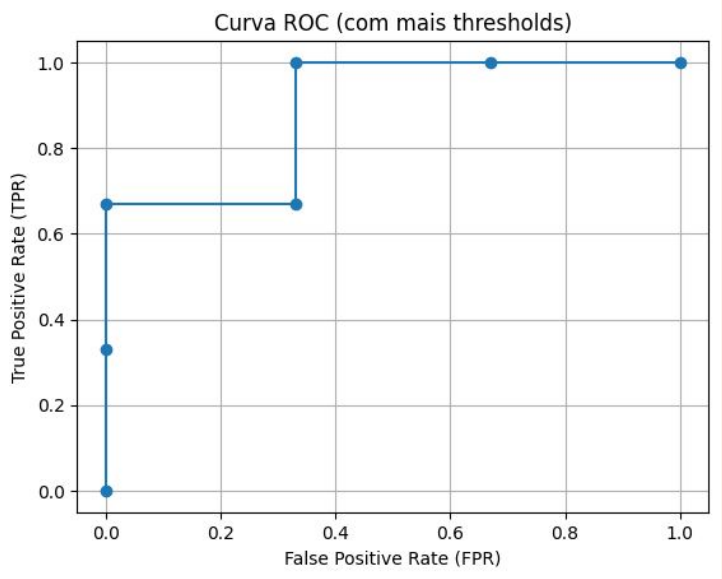

AUC

- **AUC (Area Under the Curve) = área sob a curva ROC**
- Mede a área total sob a curva ROC, resumindo a performance do modelo em um único número de 0 a 1

AUC	Qualidade
0.9 – 1.0	Excelente
0.8 – 0.9	Muito bom
0.7 – 0.8	Ok
0.5	Aleatório

Calculando AUC

$$ROC - AUC = \int_0^1 TPR(FPR)\,\mathrm{d}FPR$$

$$= \int_0^1 TPR(FPR^{-1}(x))\,\mathrm{d}x$$

Calma, calma... não criemos pânico. Tem uma forma mais fácil de calcular. Explico na próxima aula.

Vai que cai na prova.

Exercício

- Um classificador foi treinado para prever se um cliente irá cancelar a assinatura (Sim ou Não). Foram avaliados 10 clientes com os seguintes resultados.
- Monte a matriz de confusão (2x2).
- Calcule acurácia, precisão, recall e F1-score.

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

$$precisão = \frac{VP}{VP + FP}$$

$$sensibilidade = \frac{VP}{VP + FN}$$

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

Cliente	Real	Previsto
1	Sim	Sim
2	Sim	Não
3	Não	Não
4	Sim	Sim
5	Não	Sim
6	Não	Não
7	Não	Não
8	Sim	Não
9	Sim	Sim
10	Não	Não

Exercício

- Um modelo classifica frutas em Maçã, Banana ou Laranja. Os resultados para 12 amostras são apresentados na tabela.
- Construa a matriz de confusão (3x3).
- Calcule a acurácia geral.
- Compare o recall macro e o recall micro.
-

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

$$sensibilidade = \frac{VP}{VP + FN}$$

$$precisão = \frac{VP}{VP + FP}$$

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

Amostra	Real	Previsto
1	Maçã	Maçã
2	Banana	Banana
3	Laranja	Banana
4	Maçã	Laranja
5	Laranja	Laranja
6	Banana	Maçã
7	Maçã	Maçã
8	Laranja	Banana
9	Banana	Banana
10	Maçã	Maçã
11	Laranja	Laranja
12	Banana	Laranja

Exercício: Wine dataset

- A partir dos resultados obtidos com o kNN, apresente:
  - Matriz de confusão
  - Acurácia, precisão, sensibilidade e f1-score.

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

$$precisão = \frac{VP}{VP + FP}$$

$$sensibilidade = \frac{VP}{VP + FN}$$

$$f1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

Predito

Real

	Postivio	Negativo
Positivo	VP	FN
Negativo	FP	VN

Referências

- GÉRON, AURÉLIEN. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2a Edição: O'Reilly Media, 2019.
    - **Capítulo 3**

C.E.S.A.R school

Diego Bezerra

dfb2@cesar.school

in/diegodefb